jupyter Lab5 Последняя контрольная точка: несколько секунд назад (автосохранение)
Logout
File Edit View Insert Cell Kernel Widgets Help
Не доверять
Python 3
Запуск
Markdown

**Министерство науки и высшего образования Российской Федерации**

**Федеральное государственное бюджетное образовательное учреждение высшего образования**

**«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»**

**(МГТУ им. Н.Э. Баумана)**

**Факультет «Информатика и системы управления»**

**Кафедра ИУ5 «Системы обработки информации и управления»**

**Технологии машинного обучения**

**Отчет по лабораторной работе № 4**

**Ансамбли моделей машинного обучения.**

Студент:
группы ИУ5-64Б
Ведьгун Е.А.

2021 г.
Москва

## Цель лабораторной работы:

изучение ансамблей моделей машинного обучения.

## Задание:

1) Выберите набор данных (датасет) для решения задачи классификации или регресии.

2) В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.

3) С использованием метода train_test_split разделите выборку на обучающую и тестовую.

4) Обучите две ансамблевые модели. Оцените качество моделей с помощью одной из подходящих для задачи метрик. Сравните качество полученных моделей.

### | Задание 1 |

In [32]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import *
wine = load_wine()
pd_wine = pd.DataFrame(data= np.c_[wine['data'], wine['target']],
columns= wine['feature_names'] + ['target'])
```

### | Задание 2 |

In [7]:
```
pd_wine.head()
```

Out[7]:

| | alcohol | malic_acid | ash | alcalinity_of_ash | magnesium | total_phenols | flavanoids | nonflavanoid_phenols | proanthocyanins | color_intensity | hue | od280/od315 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | 14.23 | 1.71 | 2.43 | 15.6 | 127.0 | 2.80 | 3.06 | 0.28 | 2.29 | 5.64 | 1.04 | |
| 1 | 13.20 | 1.78 | 2.14 | 11.2 | 100.0 | 2.65 | 2.76 | 0.26 | 1.28 | 4.38 | 1.05 | |
| 2 | 13.16 | 2.36 | 2.67 | 18.6 | 101.0 | 2.80 | 3.24 | 0.30 | 2.81 | 5.68 | 1.03 | |
| 3 | 14.37 | 1.95 | 2.50 | 16.8 | 113.0 | 3.85 | 3.49 | 0.24 | 2.18 | 7.80 | 0.86 | |
| 4 | 13.24 | 2.59 | 2.87 | 21.0 | 118.0 | 2.80 | 2.69 | 0.39 | 1.82 | 4.32 | 1.04 | |

In [8]:
```
pd_wine.isnull().sum()
```

Out[8]:
```
alcohol                         0
malic_acid                      0
ash                             0
alcalinity_of_ash               0
magnesium                       0
total_phenols                   0
flavanoids                      0
nonflavanoid_phenols            0
proanthocyanins                 0
color_intensity                 0
hue                             0
od280/od315_of_diluted_wines    0
proline                         0
target                          0
dtype: int64
```

In [9]:
```
import seaborn as sns
sns.heatmap(pd_wine.corr())
```

Out[9]: <AxesSubplot:>

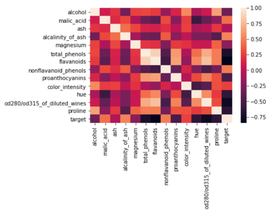


### | Задание 3 |

In [17]:
```
from sklearn.model_selection import train_test_split
```

In [18]:
```
X_train, X_test, Y_train, Y_test = train_test_split(
wine_sc, wine.target, test_size=0.33, random_state=1)
```

### | Задание 4 |

#### Случайный лес

In [20]:
```
from sklearn.ensemble import RandomForestClassifier
tree1 = RandomForestClassifier(n_estimators=5, oob_score=True, random_state=10)
tree1.fit(X_train, Y_train)
```

```
C:\Users\mi\anaconda3\lib\site-packages\sklearn\ensemble\_forest.py:540: UserWarning: Some inputs do not have OOB scores. This
probably means too few trees were used to compute any reliable oob estimates.
  warn("Some inputs do not have OOB scores. "
C:\Users\mi\anaconda3\lib\site-packages\sklearn\ensemble\_forest.py:544: RuntimeWarning: invalid value encountered in true_divi
de
  decision = (predictions[k] /
```

Out[20]:
```
RandomForestClassifier(n_estimators=5, oob_score=True, random_state=10)
```

In [23]:
```
#Просмотрим количество данных не попавших в выборку бутстрэпа в процентах.
round((1-tree1.oob_score_)*100,2)
```

Out[23]:
```
11.76
```

In [25]:
```
#Используем модель для предсказания
target1 = tree1.predict(X_test)
```

In [27]:
```
#Оценим полученную модель используя метрику Матрица ошибок
from sklearn.metrics import plot_confusion_matrix
import matplotlib.pyplot as plt
plot_confusion_matrix(tree1, X_test, Y_test,
display_labels=wine.target_names,
cmap=plt.cm.Blues, normalize='true')
```

Out[27]:
```
<sklearn.metrics._plot.confusion_matrix.ConfusionMatrixDisplay at 0x200ae88e5e0>
```

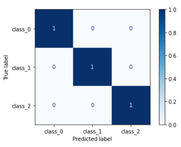


#### Градиентный бустинг

Данный метод так же предполагает последовательное многократное обучение модели с целью устранения ошибок обученных на предыдущих этапах моделей. Основным методом здесь является градиентный спуск. Решим задачу классификации для имеющихся данных.

In [28]:
```
from sklearn.ensemble import GradientBoostingClassifier
cl_gb = GradientBoostingClassifier(random_state=1)
cl_gb.fit(X_train, Y_train)
```

Out[28]:
```
GradientBoostingClassifier(random_state=1)
```

In [34]:
```
#Мы можем рассмотреть какие признаки повлияли на модель больше всего.
from operator import itemgetter
def draw_feature_importances(tree_model, X_dataset, figsize=(15,5)):
    # Сортировка значений важности признаков по убыванию
    list_to_sort = list(zip(X_dataset.columns.values, tree_model.feature_importances_))
    sorted_list = sorted(list_to_sort, key=itemgetter(1), reverse = True)
    # Названия признаков
    labels = [x for x, _in sorted_list]
    # Важности признаков
    data = [x for _,x in sorted_list]
    # Вывод графика
    fig, ax = plt.subplots(figsize=figsize)
    ind = np.arange(len(labels))
    plt.bar(ind, data)
    plt.xticks(ind, labels, rotation='vertical')
    # Вывод значений
    for a,b in zip(ind, data):
        plt.text(a-0.05, b+0.01, str(round(b,3)))
    plt.show()
    return labels, data
_,_ = draw_feature_importances(cl_gb, pd_wine)
```

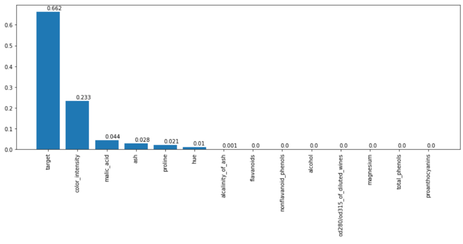


In [ ]: